

Regresión

Juan Pájaro

Maestro en ingeniería de sistemas

Phd(c) en Ingeniería

Docente del dpto de epidemiología clínica y bioestadística

Juanpajaro@javeriana.edu.co


Agenda

- Flujo de trabajo
- Actores
- Métricas de evaluación
- Taller
- Principios basados en la regresión lineal
- Sesgo vs varianza
- Tareas analíticas
- Tareas de modelos de lenguaje

Flujo de trabajo de aprendizaje automático



Actores



- Investigador principal.
- Director de investigaciones.
- Investigador asociado.
- Administrador de bases de datos.
- Estadístico o Ingeniero de aprendizaje automático.



Métricas de evaluación

- El R^2 representa la proporción de la varianza total de la variable dependiente (Y) que es explicada por la(s) variable(s) independiente(s) (X) del modelo.
- El valor de R^2 siempre oscila entre 0 y 1 (o 0% y 100%):
 - $R^2 = 0$: El modelo no explica nada de la variabilidad de los datos. Es tan útil como predecir siempre usando el promedio de Y.
 - $R^2 = 1$: El modelo explica perfectamente toda la variabilidad. Todos los puntos de datos caen exactamente sobre la línea de regresión.
 - Valores intermedios: Un R^2 de 0.70 significa que el 70% de la variación en los datos de salida se explica por los cambios en las variables de entrada.

Taller

- Resolver el taller.
- Identificar los pasos.
- Entender las variables independientes.
- Entender la variable resultado.
- Entender cual es el algoritmo que se usa.
- Entender la interpretación de la gráficas SHAP.

¿Qué es el aprendizaje realmente?




¿Cómo se estima?

$$\begin{aligned} E(Y - \hat{Y})^2 &= E[f(X) + \epsilon - \hat{f}(X)]^2 \\ &= \underbrace{[f(X) - \hat{f}(X)]^2}_{\text{Reducible}} + \underbrace{\text{Var}(\epsilon)}_{\text{Irreducible}}, \end{aligned}$$

¿Cómo se estima?



Algoritmos paramétricos

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p.$$




¿Cómo se estima?

Algoritmos NO paramétricos



Intercambio entre exactitud e interpretabilidad




Supervisado vs NO supervisado



Calidad del ajuste

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2,$$

mean squared error (MSE)



Sesgo y varianza




FIGURE 2.9. Left: Data simulated from f , shown in black. Three estimates of f are shown: the linear regression line (orange curve), and two smoothing spline fits (blue and green curves). Right: Training MSE (grey curve), test MSE (red curve), and minimum possible test MSE over all methods (dashed line). Squares represent the training and test MSEs for the three fits shown in the left-hand panel.

Sesgo y varianza




FIGURE 2.10. Details are as in Figure 2.9, using a different true f that is much closer to linear. In this setting, linear regression provides a very good fit to the data.

Sesgo y varianza




FIGURE 2.11. Details are as in Figure 2.9, using a different f that is far from linear. In this setting, linear regression provides a very poor fit to the data.

Sesgo y varianza




FIGURE 2.12. Squared bias (blue curve), variance (orange curve), $\text{Var}(\epsilon)$ (dashed line), and test MSE (red curve) for the three data sets in Figures 2.9–2.11. The vertical dashed line indicates the flexibility level corresponding to the smallest test MSE.

Técnicas de minería de datos



Regresión

Clasificación

Clustering

The TRIPOD-LLM reporting guideline for studies using large language models

- Reporte transparente de modelos multivariados para el pronóstico y diagnóstico individual.

Diseño de investigación	Definición
Desarrollo de un nuevo LLM	Construcción de un nuevo modelo de lenguaje desde cero o ajuste fino sustancial de modelos base existentes para desarrollar nuevas funcionalidades o adaptarse a nuevas tareas.
Métodos LLM	Investigaciones teóricas o cuantitativas sobre nuevas arquitecturas de modelos, nuevos métodos computacionales para entender los LLM o para optimizar el prompting.
Evaluación de LLM	Evaluación de la eficacia, precisión o adecuación de un LLM para tareas específicas en salud, incluyendo riesgos o sesgos asociados.
Evaluación en entornos clínicos	Evaluación del LLM en flujos de trabajo clínicos, considerando integración e impacto en resultados clínicos, administrativos o del personal.

Tarea de LLM	Definición
Procesamiento de texto	Manipulación y procesamiento de bajo nivel de datos de texto, incluyendo tokenización, análisis sintáctico y reconocimiento de entidades.
Clasificación	Asignación de etiquetas predefinidas a los datos de texto.
Respuesta a preguntas complejas	Proporciona respuestas detalladas a consultas complejas con razonamiento sobre múltiples documentos o evidencias.
Recuperación de información	Obtención de información relevante desde grandes conjuntos de datos según consultas específicas, como en revisiones de literatura o antecedentes clínicos.
Agente conversacional (chatbot)	Interacción conversacional con usuarios, usado para interacción con pacientes, avisos de salud o asistencia virtual.
Generación de documentación	Creación automática de documentación médica desde datos clínicos, dictados o grabaciones.
Resumir y simplificar	Reducción o simplificación de textos largos para mejorar la comprensión.
Traducción automática	Conversión de texto de un idioma a otro.
Pronóstico de resultados	Predicción de resultados médicos futuros con base en datos históricos.