

Regresión continuación

Juan Pájaro

Maestro en ingeniería de sistemas

Phd(c) en Ingeniería

Docente del dpto de epidemiología clínica y bioestadística

Juanpajaro@javeriana.edu.co

Agenda

- Estimación de los parámetros
- Evaluación de la exactitud del modelo
- Principios del modelo de regresión lineal
- Preprocesamiento
- Colab anterior
- Taller

Estimación de los parámetros

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

$$(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$$

$$e_i = y_i - \hat{y}_i$$

$$\text{RSS} = e_1^2 + e_2^2 + \dots + e_n^2$$

Suma de los residuos cuadrados

Estimación de los parámetros

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x},$$

Evaluación de la exactitud del modelo

$$\text{RSS} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$\text{RSE} = \sqrt{\frac{1}{n-2} \text{RSS}} = \sqrt{\frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

$$\text{TSS} = \sum (y_i - \bar{y})^2$$

$$R^2 = \frac{\text{TSS} - \text{RSS}}{\text{TSS}} = 1 - \frac{\text{RSS}}{\text{TSS}}$$

Evaluación de la exactitud del modelo

- El R^2 representa la proporción de la varianza total de la variable dependiente (Y) que es explicada por la(s) variable(s) independiente(s) (X) del modelo.
- El valor de R^2 siempre oscila entre 0 y 1 (o 0% y 100%):
 - $R^2 = 0$: El modelo no explica nada de la variabilidad de los datos. Es tan útil como predecir siempre usando el promedio de Y.
 - $R^2 = 1$: El modelo explica perfectamente toda la variabilidad. Todos los puntos de datos caen exactamente sobre la línea de regresión.
 - Valores intermedios: Un R^2 de 0.70 significa que el 70% de la variación en los datos de salida se explica por los cambios en las variables de entrada.

Principios del modelo de regresión lineal

- Simple: cuando hay una sola variable.

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- Múltiple: cuando existen muchas variables.

$$f(X) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p.$$


Principios del modelo de regresión lineal

- También puede ser polinomial, cuando no existe relación lineal.
- Cuando se habla del modelo lineal generalizado es una regresión lineal que acomoda las variables que no siguen una distribución normal.
- LASSO es una forma de regresión que incrementa la exactitud de la predicción siguiendo un algoritmo de regularización y selección de variables.

Flujo de trabajo de aprendizaje automático



Preprocesamiento



Preprocesamiento

- Seleccionar características acorde a la base de conocimiento.
- One-hot encoding – variables categóricas.
- Target-encoding – variables categóricas.
- Standar scaler – variables numéricas.

$$X'_i = \frac{X_i - \mu}{\sigma} = \frac{X_i - X_{\text{mean}}}{X_{\text{std}}}$$