

Clasificación

Juan Pájaro

Maestro en ingeniería de sistemas

Phd(c) en Ingeniería

Docente del dpto de epidemiología clínica y bioestadística

Agenda


- Elementos de un algoritmo de AA: Árboles de decisión
- Evaluación
- Método (gestión de datos, entrenamiento, evaluación)
- Taller

Elementos de un algoritmo de AA: Árboles de decisión

1. Datos
2. Función matemática
3. Función de pérdida
4. Algoritmo de optimización





¿Qué es un árbol de decisión

- Nodo raíz
- Nodos de decisión
- Ramas
- Hojas
- Poda



Función matemática

- En un árbol de decisión, la función matemática $f(x)$ no es una ecuación lineal o polinómica continua, sino una función definida por partes (piecewise function).
- El algoritmo divide el espacio de características (los datos de entrada) en regiones rectangulares disjuntas $R_1, R_2, \dots, R_m$.
- Para cualquier entrada x que caiga en la región R_j , la predicción es la misma (normalmente la moda para clasificación o la media para regresión).



Función matemática

Formalmente, se puede expresar como:

$$f(x) = \sum_{m=1}^M c_m I(x \in R_m)$$

Donde:

- M es el número de hojas (nodos terminales).
- R_m es la región del espacio representada por la hoja m .
- c_m es la constante de predicción para esa región.
- I es la función indicadora que vale 1 si x está en la región y 0 si no.

Función de pérdida

- La función de pérdida mide qué tan "buena" es una división en un nodo.
- El objetivo es que cada división resulte en subgrupos más puros que el original.
 - Para Clasificación: Se suelen usar dos métricas principales:
 - Entropía: Mide el desorden o la incertidumbre.
 - Coeficiente de Gini: Mide la probabilidad de clasificar incorrectamente un elemento elegido al azar.
 - Para Regresión: Error Cuadrático Medio (MSE): Busca minimizar la varianza de los datos dentro de cada nodo.

Concepto de entropía

- La entropía es un concepto fundamental en la teoría de la información (y por extensión, en los árboles de decisión como ID3) que mide el grado de desorden o incertidumbre en un conjunto de datos.
- Imagina que tienes una bolsa con bolas de colores:
 - Baja Entropía (Nodo Puro): Todas las bolas son rojas. No hay incertidumbre; si sacas una, sabes que será roja.
 - Alta Entropía (Nodo Impuro): Hay 50 bolas rojas y 50 azules. La incertidumbre es máxima; tienes la misma probabilidad de sacar cualquiera de las dos.

Ejemplo práctico

Imagina que estás analizando datos de pacientes para predecir riesgo cardíaco:

- Nodo Padre: Tienes 10 pacientes (5 con riesgo, 5 sin riesgo). La Entropía es 1.0 (máximo desorden).
- División A (Fumador): Separa perfectamente a los 5 con riesgo de los 5 sin riesgo. La entropía de los hijos es 0.
- División B (Hobby: Cine): Los grupos quedan igual de mezclados (3 con riesgo y 2 sin riesgo en un lado; 2 y 3 en el otro). La entropía apenas baja.
- El árbol elegirá "Fumador" como el nodo de decisión porque reduce drásticamente la incertidumbre.


Algoritmo de optimización

Pasos (ID3, C4.5 o CART):

1. Búsqueda Exhaustiva: En cada nodo, el algoritmo prueba todas las características posibles y todos los puntos de corte posibles.
2. Selección Óptima: Elige el corte que maximiza la reducción de la función de pérdida (esto se conoce como Ganancia de Información).
3. Recursión: Repite el proceso para los nodos hijos resultantes.
4. Parada: El algoritmo se detiene cuando se alcanza una profundidad máxima, los nodos son puros o no hay suficiente ganancia para continua.


Bagging vs Boosting

Bagging



Parallel

Boosting




Sequential

Evaluación

Métrica	¿Qué nos dice?
Precisión	De todos los que el modelo dijo que estaban "enfermos", ¿cuántos realmente lo estaban?
Sensibilidad (Recall)	De todos los que realmente estaban "enfermos", ¿cuántos logró detectar el modelo?
F1-Score	Un equilibrio entre las dos anteriores; muy útil si tus datos están desbalanceados.

Metodo



Taller