

Cluster o agrupamiento

Juan Pájaro

Maestro en ingeniería de sistemas

Phd(c) en Ingeniería

Docente del dpto de epidemiología clínica y bioestadística

Agenda

1. Aprendizaje no supervisado
2. ¿Qué es kmeans?
3. Conceptos fundamentales
4. ¿Cómo funciona el algoritmo?
5. ¿Cómo se evalúa?
6. Taller kmeans
7. ¿Y si tenemos datos categóricos?
8. Taller kmodes

Aprendizaje no supervisado

- No existe la variable dependiente.
- El conocimiento para interpretar los datos se da al final, una vez construido el modelo.

¿Qué es kmeans?

- El K-means (o agrupamiento de K-medias) es uno de los algoritmos de aprendizaje no supervisado más populares y sencillos.
- Su objetivo es dividir un conjunto de datos en K grupos (clusters) distintos, de tal manera que los datos dentro de cada grupo sean lo más similares posible entre sí.

Conceptos fundamentales


- Centroide: Es el "centro" geométrico de un grupo. En muchos casos es el promedio de todas las posiciones de los puntos en ese cluster.
- Distancia: El algoritmo suele usar la distancia euclidiana para medir qué tan cerca está un punto de un centroide.

¿Cómo funciona el algoritmo?

1. Inicialización: Se seleccionan aleatoriamente K puntos en el espacio de datos para que actúen como los centroides iniciales.
2. Asignación: Cada punto de los datos se asigna al centroide que tiene más cerca.
3. Actualización: Una vez que todos los puntos están asignados a un grupo, se calcula el nuevo centro de ese grupo (el promedio de sus puntos). Ese promedio se convierte en el nuevo centroide.
4. Repetición: Se repiten los pasos 2 y 3 hasta que los centroides ya no se muevan o se alcance un límite de intentos.

¿Cómo se evalúa?

- ¿Cómo saber si necesitas 2, 3 o 5 grupos?
- Se suele usar una gráfica que mide la Inercia (la suma de las distancias al cuadrado dentro de los grupos).
- Cuando añadir un grupo más ya no reduce significativamente la inercia, verás un "doblez" en la gráfica. Ese es tu número ideal de K.



¿y si tenemos datos en categorías?

- Usamos la frecuencia.
- No podemos usar kmeans porque los datos son categorías. No se puede distinguir entre “Rojo” y “Azul”.
- Funciona igual que kmeans, pero con una métrica diferente.
- Iniciación, asignación, actualización y repetición.

Disimilitud (Distancia)

- En lugar de medir qué tan lejos están los puntos, el algoritmo cuenta cuántas categorías NO coinciden.
 - Si comparas dos registros: [Azul, Doctor, Casado] y [Azul, Chef, Soltero].
 - Tienen 1 coincidencia (Azul) y 2 diferencias. Su "distancia" o disimilitud es 2.

La moda

- El centro (llamado Moda) es el valor que más se repite en cada columna para ese grupo.
- Ejemplo: Si en un grupo de 10 personas hay 8 "Ingenieros", 1 "Chef" y 1 "Músico", la moda de ese grupo para la columna de profesión será "Ingeniero".

Gracias